

图像配准（翻译与讲解版）

**开头引入和工具使用部分有适当删节，部分地方有讲解增添
可能只考大题，甚至不一定考很多分，但是这一部分是书上没有的，
因此做出适当中文翻译和讲解，供理解学习使用。
有一些简单解释是译者加的，可能不考，只是便于理解。**

原PPT：吴丹 翻译和讲解：迎晞向前

为什么要配准？

- 医学图像不是孤立的，医生通常需要：
- 纵向比较：比如看化疗后肿瘤有没有缩小，必须把前后的片子对齐。
- 多模态融合：CT看骨头清楚，MRI看软组织清楚，PET看代谢。把它们叠在一起（对齐）才能精准诊断。
- 群体分析：为了研究某种病（如阿尔茨海默症），需要把几百个病人的脑图拉伸对齐到一个标准脑模版上，才能统计哪里萎缩了。




Contents

- 线性配准 (Linear registration)
 - Registration Basic (配准基础)
 - Registration Pipeline (配准流程)
 - Transformation (仿射变换)
 - Similarity Metrics (相似性度量)
 - Optimizer (优化器: 优化参数)
- 非线性配准 (Non-linear registration)
 - Diffeomorphic transformation
 - Jacobian matrix
- Toolbox and pipeline (工具箱和流程)

配准的定义

配准的定义就是将一幅图像中的点映射到另一幅图像中对应点的空间变换



- **配准**

- 优化描述源图像与参考（模板）图像之间空间变换的参数
- 根据确定的变换参数重新采样


Registration: definitions

给定一组匹配的特征点:

$$\{x_i, x'_i\}$$

源图像的点

目标图像的点



And a transformation (变换) :

$$x'_i = f(x_i; p)$$

变换函数

参数

Goals


- 优化描述空间变换的参数 p
- 定义变换函数 f

Registration Basis

- Point-based methods (基于点)
- Surface-based methods (基于表面)
- Intensity-based methods (基于灰度)

辅助理解:

1. 背景: CT (计算机断层扫描) 能清晰显示解剖结构 (如骨骼), 而PET (正电子发射断层扫描) 能显示代谢活动 (如肿瘤区域)。医生常常需要将两者融合, 以精确定位高代谢的病灶到底在哪个解剖位置上。
2. 图示: 图中左边是CT, 右边是PET。红色的点就是在两种图像上找到的同名地标点 (比如胸骨的顶端、某个特定的椎体等)。红线将这些成对的点连接起来。
3. 一旦我们手动或自动地找到了足够多的地标点对 (比如在3D空间中至少需要3-4对), 就可以通过数学计算 (如最小二乘法) 直接解出能够将源图像上的点——映射到目标图像对应点上的变换参数。





Landmark based registration between CT-PET

Registration Basis: Surface-based methods (基于表面)


- Point-based methods
- Surface-based methods
- Intensity-based methods

比如，医生想研究老年痴呆症患者的大脑皮层是不是比正常人更薄。
通过这种方法，他可以：


1. 分别提取患者和正常人大脑皮层的“轮廓”。
2. 将两个轮廓对齐。
3. 直接在对齐后的模型上测量和比较各个位置的皮层厚度差异。



Original




WM/GM cortex mesh




WM (red), GM (green)

Registration Basis: Surface-based methods (基于灰度)


- Point-based methods
- Surface-based methods
- **Intensity-based methods**



fixed image



moving image



MSE
Registered

Registration Pipeline (配准的流程)

2024-2025 考试真题：画配准流程图






Image Registration Basic Steps

1. 定义变换类 (刚体, 仿射, 非线性)
2. 定义相似性指标/目标度量 (同源特征, 强度)
3. 优化变换参数以最大化相似度指数 (又称最小化视差指数, 成本函数)




Registration Pipeline (配准的流程)

2024-2025 考试真题：画配准流程图



Linear Transformation 线性变换



$$T = \begin{bmatrix} \text{scale} & \text{rotation} & \text{translation} \\ a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ \text{shear} & 0 & 1 \end{bmatrix}$$

Affine Transform


- Translation
 - Rotation
 - Scaling
 - Shearing
- rigid (Translation, Rotation)
 9-degree Affine (Translation, Rotation, Scaling)
 12-degree Affine (Translation, Rotation, Scaling, Shearing)

- 刚体变换 (Rigid) : 仅包含**平移和旋转**
- 9 自由度仿射变换: 在刚性变换基础上增加**缩放**
- 12 自由度仿射变换: 在 9 自由度基础上增加**剪切**

Non-linear非线性变换

- 仿射变换 (12自由度)

当两个物体的局部形状有本质不同时，只靠简单的整体拉伸（线性/仿射变换）是绝对不够的。



增加自由度



Affine

Elastic

Diffeomorphic




拓展讲解:

Elastic (弹性): 车子就像是用柔软的橡胶做的，车顶被“捏”得更圆了，车身也被“拉”得更长了。这是一种局部变形。

Diffeomorphic (微分同胚): 这是最理想、最高级的非线性变换。它不仅像“弹性”变换一样可以进行局部变形，还保证了变形过程是极度平滑的，不会出现撕裂、折叠或者扭曲成一团的“不合理”情况。

Non-linear


Deformation Field (变形场)



- 每一个箭头都对应着原始图像上的一个像素点。
- 箭头的方向告诉这个像素点应该朝哪个方向移动。
- 箭头的长短告诉这个像素点应该移动多远的距离。


Registration Pipeline (配准的流程)

2024-2025 考试真题：画配准流程图



Why interpolation

•为什么需要插值？因为变换后的坐标通常不是整数而像素必须在整数格子上。需要根据周围像素估算该位置的值。
1) 一些目标像素可能没有被覆盖，2) 多个源像素映射到同一个目标像素



原始图像具有整数坐标


Interpolation methods (Lecture 2)

- Nearest interpolation (最邻近插值)
- Bilinear interpolation (双线性插值)
- Bi-Cubic interpolation (双三次插值)
-


2-D (16 pixels):

$$f(x, y) = \sum_{i=0}^3 \sum_{j=0}^3 a_{ij} x^i y^j$$


e.g. Least square method, to minimize the squared error of the interpolation function
最小二乘法，求插值函数的平方误差最小




1D nearest-neighbour




Linear




Cubic



2D nearest-neighbour




Bilinear



Bicubic

Registration Pipeline (配准的流程)

2024-2025 考试真题：画配准流程图



Inter-modality & Intra-modality


- Metrics
 - Depends on the images to be registered
 - 相似性取决于要被配准的图像

- Intra-modality (单模态)

- 同类图像配准 (如 T1配准到T1) 。

- Inter-modality (多模态)


- 不同类图像配准 (如 MRI配准到CT) 。



Inter-modality & Intra-modality

- Alignment (对齐, 这里是运动校正)
 - Same modality and same subject (相同模态和相同被试):
 - 这是进行这种对齐的**前提条件**。

BOLD fMRI



Squares of Intensity Differences (SSD)

误差平方和算法/均方误差

$$SSD = \frac{1}{N} \sum_i^N |A(i) - B'(i)|^2 \quad \forall i \in A \cap B'$$

假设

- 差异仅仅来自高斯噪声

Work well for

- 磁共振序列图像/功能性磁共振实验

Failure

- 数据与理想情况偏离太多
- 噪声
- 退化 (运动伪影, 模糊, ...)

图像比率一致性 (Ratio image uniformity)

Calculated over $A \cap B'$

1. 确定体素的数量N。 (Determine the number of voxels N)

2. 计算图像比率: Ratio image $R(i) = \frac{B'(i)}{A(i)}$

3. 计算平均图像比率: Mean of R: $\mu_R = \frac{\sum_i R(i)}{N}$

4. 计算图像比率的标准差:

$$\text{Standard deviation of R: } \sigma_R = \frac{1}{N} \sum_i (R(i) - \mu_R)^2$$

$$5. \text{RIU} = \sigma_R / \mu_R$$

Work well for

- 当图像相差一个增益因子时很有用
- 例如, 多幅PET图像、脑部MR序列配准等

• **原理:** 计算两图的比值图像, 看比值的均匀度。

• **适用:** 图像之间仅存在增益因子差异时 (如PET或序列MRI) 。

Correlation Coefficient (CC, 相关系数)

$$CC = \frac{\sum_i (A(i) - \bar{A})(B'(i) - \bar{B}')}{\{\sum_i (A(i) - \bar{A})^2 \sum_i (B'(i) - \bar{B}')^2\}^{1/2}} \quad \forall i \in A \cap B'$$

Assumption

- A & B' are linearly related (A和B线性相关)


Work well

- Good for intramodal images with varying intensity scales
- 适用于具有不同强度尺度的模内图像


Inter-modality & Intra-modality

Intra-modal registration (单模态配准)

- 来自相同模态/相机的不同被试
- 空间标准化



Affine registration 仿射配准



Non-linear registration- 非线性配准


Template Images 模板图像



- 简单解释:
- 模板通常是通过平均成百上千个健康人的大脑图像制作出来的, 代表了一个最普遍、最平均的大脑形态。
- 上面两步配准操作的最终目的, 就是让每一个人的大脑都和这个模板图像完美对齐。

Inter-modality & Intra-modality

fMRI



T1w




Inter-modal registration (多模态配准)

Information 信息

- What is information?
- 什么是信息?
- Claude Shannon
 - father of information theory
- 香农——信息学之父
- Degree of Surprise:
 - More surprise $\rightarrow$ more information
 - Surprise = Unlikely = low probability
 - 越惊讶，信息量越大
 - 但惊讶也代表更低的概率

简单解释：不断调整图像的位置，直到两张图能够最大程度地“解释”对方，让它们像素值的组合变得最“不令人惊讶”、最“有规律”，也就是让它们的“互信息”达到最大！（当然也有其他信息量的度量）




Example

- 低概率=高信息
 - 太阳东升西落 (很正常, 不会让你惊讶, 这是句废话)
 - 太阳西升东落 (很惊讶, 蕴含大量信息)

- Property:
 - 连续
 - 非负 $[0, 1]$
 - 单调
 - 可加性

Information: $I(x) := -\log(p(x))$



熵

- 信息的期望，或称之为熵，如下表示：

$$H(X) := E[I(x)] = \sum p(x)I(x) = - \sum p(x) \log p(x)$$

- 联合熵:

$$H(X, Y) := - \sum p(x, y) \log p(x, y)$$

熵

- 条件熵

$$\begin{aligned} H(Y|X) &= - \sum p(x) H(Y|X = x) \\ &= - \sum_x p(x) \sum_y p(y|x) \log p(y|x) \\ &= - \sum_{x,y} p(x, y) \log p(y|x) \end{aligned}$$

互信息

- 相对熵：分布 q 和 p 之间的距离

$$D(p||q) = H(q) - H(p) = - \sum p(x) \log q(x) - \left[- \sum p(x) \log p(x) \right] = \sum p(x) \log \frac{p(x)}{q(x)}$$

- 互信息 = 联合分布 $p(x,y)$ 与 边缘分布乘积 $p(x)p(y)$ 之间的相对熵,
- 衡量的就是 “**实际情况**” 比 “**假设完全独立的情况**” 要“确定”多少。
- 两者差距越大, 说明A和B的关联性越强, 互信息就越高。

$$I(X; Y) = H(p(X)p(Y)) - H(p(X, Y)) \quad p := p(X, Y), q := p(x)p(y)$$


$$= \sum p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

- 互信息的诠释: X包含在Y中的信息量
- 也可以等价为, 如果Y已知, X中的信息减少量


互信息

$$\begin{aligned} I(X; Y) &= \sum p(x, y) \log \frac{p(x, y)}{p(x)p(y)} \\ &= \sum p(x, y) \log \frac{p(x|y)}{p(x)} \\ &= - \sum p(x, y) \log p(x) \\ &= H(X) - H(X|Y) \end{aligned}$$

$$I(X; Y) = H(X) + H(Y) - H(X, Y)$$




联合直方图




$$h_{ab}[a(i, j), b(i, j)] = n_{[a(i, j), b(i, j)]}$$

归一化联合直方图（联合概率分布函数，PDF）

$$p_{ab}[a(i, j), b(i, j)] = \frac{h_{ab}[a(i, j), b(i, j)]}{\sum_{i, j} h_{ab}[a(i, j), b(i, j)]}$$



The identity




Lower similarity


- The identity (完全相同): 所有的点都会完美地落在**对角线**上。
- Lower similarity (相似度低): 像素值的对应关系就是一团乱麻，联合直方图上的点会像雪花一样**散乱分布**。

• **配准过程**: 电脑在配准时，会不断调整浮动图像的位置，它的目标就是让这个联合直方图从“散乱的雪花”**变得越来越“聚集”**，最好能聚集成一条清晰的线或曲线。


Example joint PDF



(a)



(b)



(c)

Identical MR image
(相同的MR图像)

the identity: 完美对齐时，是一条直线。
translation of 2/5 mm: 即使只有几毫米的微小平移，这条线也立刻变得模糊、发散。



CT and MRI

不同模态像素值关系不是简单的“相等”，所以即使完美对齐，联合直方图也不是一条直线，而是呈现出一种特定的、复杂的形状。配准的目标就是要让这个直方图变得尽可能的“锐利”和“结构清晰”，而不是模糊一团。

MR and PET

Mutual Information (MI) as a measure 互信息作为度量

- Correct registration results in a **decrease in joint entropy, and increase of MI**
- 正确的配准会导致**联合熵的降低和互信息的增加**



- Good for both Intra & Inter-modality registration
- 对单一模态或多模态（跨膜态）配准都有好处

Summary (翻译在下一页, 本页保持原貌)

Cost Function	Modality Assumption	Robustness	Computational Cost	Best Use Case
SSD / MSE	Intramodal	Low (noise-sensitive)	Low	Same modality, no intensity changes
RIU	Intramodal (scaled)	Moderate	Moderate	Same modality, multiplicative differences
Cross-Correlation	Intramodal / Linear	High (linear changes)	Medium	Same modality, brightness/contrast changes
Mutual Information	Multimodal	Very High	High	Different modalities


总结

代价函数	模态假设	鲁棒性/稳健性	计算成本	最佳应用场景
SSD / MSE	单模态	低(噪声敏感)	低	相同模态，无灰度变化
RIU	单模态 (存在缩放关系)	中	中	相同模态，存在乘性差异 (如 $I2=k \cdot I1$)
Cross-Correlation	单模态 (线性关系)	高，针对线性变化	中	相同模态，存在亮度/对比度变化
Mutual Information	多模态	非常高	高	不同模态间


Example: Spatial normalization

对20个被试进行空间标准化


Mean Square Error



Cross correlation



Mutual Information




锐度降低

Avants BB, Tustison NJ, Song G, Cook PA, Klein A, Gee JC. A reproducible evaluation of ANTs similarity metric performance in brain image registration. Neuroimage. 2011 Feb 1;54(3):2033-44.

Spatial Normalization

- Application: subject to reference




Contents

- Linear registration
 - Transformation
 - Similarity metric
 - Optimization
- Non-linear registration
 - Diffeomorphic transformation
 - Jacobian matrix
- Toolbox and pipeline


Registration Pipeline (配准的流程)

2024-2025 考试真题：画配准流程图



优化的方法


- 优化：根据“代价函数(cost function)”找到一些“最佳”参数
- “代价函数(cost function)”通常与基于某种模型的概率有关



如何避免陷入“局部最优”，而找到真正的“全局最优”？

优化的方法

- 往往解析解是不存在的
- 代价函数必须通过迭代来最小化(暴力搜索或用更聪明地办法)
- 优化需要计算导数/梯度
 - *One-dimensional search* 一维搜索
 - *Gradient descent* 梯度下降
 - *Variable metric* 可变度量法



优化的方法

Similarity Index/Object function

- Intra-modal单模态
 - Mean squared difference (minimise) 均方差最小
 - Normalised cross correlation (maximise) 归一化互相关最大
 - Entropy of difference (minimise) 差值熵最小
- Inter-modal (or intra-modal) 多模态
 - Mutual information (maximise) 互信息最大
 - Normalised mutual information (maximise) 归一化互信息最大


方法举例: 梯度下降

- 将任意配准相似度指标C视为两幅图像和M个变换参数的函数

$$\nabla C(A, B; \mathbf{p}) = \left[\frac{\partial C}{\partial p_1}, \dots, \frac{\partial C}{\partial p_M} \right]$$

- 梯度下降根据以下式子更新

$$p_{t+1} = p_t - \underset{\substack{\uparrow \\ \text{step size}}}{\eta} \nabla C(A, B; \mathbf{p})$$



- 检查新参数是否提高了相似度指标, 如果没有则减小步长, 并重复之


方法举例: 梯度下降

- 数值近似


$$\frac{\partial C}{\partial p_i} \approx \frac{C(p_1, \dots, p_i + \Delta p_i, \dots, p_M) - C(\mathbf{p})}{\Delta p_i A}$$

- Choice of delta will affect results Δ 的选择将影响结果
- Can always be computed 数值近似总是可以计算的（而计算梯度的偏导数有时在数学上很复杂甚至不可能）
- Better alternative when possible: directly computing derivative from the cost function 当代价函数的导数（梯度）是直接可以计算的时候，还是直接计算梯度比较好。


配准结果




Initial errors




Iteration 100




Iteration 200



Iteration 300



Final: 498 iterations




- 简单解说:
- 初始时, 两图相减的差值图像非常亮, 说明差异巨大。
- Iteration 100/200/300: 随着迭代, 差值图像越来越暗, 说明两图越来越接近。
- Final: 498 iterations: 最终, 差值图像几乎是全黑的, 说明配准非常成功。

实践中存在的问题

$$A(m, n) - sB(T(m, n; p))$$

- 对于SSD配准，通常需要增加一个灰度缩放因子s来处理亮度差异
 - “局部最优”的问题：如果初始位置（第一步的参数）不好，很可能掉进小山谷。
"multi-start" approaches (多起点方法) 是一种策略：从多个不同的随机初始点开始优化，最后看哪个结果最好。
 - **multi-resolution scheme (多分辨率方案)** 是解决局部最优的常用方法
-
- 第一次以粗分辨率运行（例如重采样到6x6x6mm）
 - 第二级分辨率（例如重采样到3x3x3 mm）
 - 用1.5x1.5x1.5mm重复一次




配准算法评估


- A gold standard is available 存在金标准
 - Derived from simulated data or fiducial markers
 - 源自模拟数据或基准标记物
- User selected **landmarks** or **manually defined structures** may be used to validate the registration result
- 用户手动选择的标记点或手动定义的结构可用于验证配准结果
- Visual assessment (overlays, checkerboard patterns, average images)
- 视觉评估（叠加、棋盘格模式、平均图像）

Visual assessment (视觉评估)

Overlay (叠加)



Check board (棋盘格)



Registration of SPGR and T2 images

Contents


- Linear registration
 - Previously: interpolation & spatial transform
 - Similarity metric
 - Optimization
- Non-linear registration
 - Diffeomorphic transformation
 - Jacobian matrix
- Toolbox and pipeline

Nonlinear Registration 非线性配准

- 一种方法是使用变形场的参数化表示，并针对这些参数来优化相似性函数。
- 另一种方法是将（大的）变换分解为更小的仿射/刚体变换，并从这些小变换中构建一个平滑的变形
- 初始化（初始参数选择）和局部极小值（局部最优）等问题变得更加突出

Nonlinear Registration Methods 非线性配准方法

一个非线性变换可以由
一个**变形场**来表示




Deformation Field $u: \Omega_I \rightarrow \mathbb{R}^3$

- Diffeomorphic (微分同胚)
 - Demons
 - LDDMM
 - HARMMER
- Free-form Deformation (自由变形)
-

Diffeomorphic Deformation (微分同胚变形)


- 在数学中，微分同胚是指光滑流形之间的同构关系。
- 一个变换是微分同胚的，则它是可逆的，可以将一个可微流形映射到另一个流形，使得该函数及其逆函数均是可微的（变形过程没有尖锐的拐点或断裂）。
- 我们追求的“**微分同胚映射**”，强制要求最终得到的那个“变形场”或“变换”，必须严格满足“微分同胚”的所有数学属性。
 - 关键要素: 变形是由一系列微小变形的复合构成的。
 - 一对一，可逆，平滑
 - 保持拓扑结构（译者注：变形不会撕裂或者粘连组织）
 - 对于计算解剖学至关重要（Essential for computational anatomy）



Diffeomorphic Deformation (微分同胚变形)


Diffeomorphic mapping

Homeomorphism 同胚




One-to-one mapping
一对一映射


Differentiable 可微



Smooth & differential mapping
平滑和可微映射





Topology 拓扑



Classical Demons Algorithm (Demons算法)


- Using more convenient notation (采用更简便的符号)
 - F , M : fixed and moving images (固定和浮动图像)
- Demons iterations 恶魔算法迭代步骤
 - 初始化位移场 s (例如设为恒等变换)
 - 从 M 中所有空间梯度非零的像素点开始: 记为集合 D_M
 - 为 D_M 中的所有点 P 计算基本位移场 $u(P)$
 - 计算图像力 u , 将已经过 s 变换的 M (即 $M \circ s$) 推向 F 。也就是说, 让 $M \circ (s+u)$ 比 $M \circ s$ 更像 F 。
 - $s \leftarrow$ 对 $s+u$ 进行高斯平滑 (保证最终变形场光滑合理, 符合微分同胚)



简单讲解图像力背后的含义：算法的“力”是来自于图像的边缘。梯度为零的区域是平坦的，没有信息，我们不关心。所以，我们只在有灰度变化的地方（即图像有内容、有边缘的地方）计算变形。恶魔算法根据图像梯度来推动像素。如果像素值低于目标值，就沿着梯度方向推；如果高于目标值，就沿着梯度的反方向推。

- 注： u 是迭代中计算出的一个临时的、微小的位移。这是算法最核心的一步。它根据固定图像 F 的梯度和两图的灰度差异，计算出在点 P ，浮动图像应该“被推”多远、“被推”向哪个方向，才能让它更像固定图像。这个“推力”就是所谓的“恶魔之力 (Demons force)”。

Example




微分同胚的“拓扑保持”特性



直接让变形场在缺口处发生了折叠和撕裂

Example


Pairwise registration problem




Demons result




Large Deformation Diffeomorphic Metric Mapping (LDDMM) 大变形微分同胚度量映射 (LDDMM)



Fluid registration



Computing large deformation metric mappings via geodesic flows of diffeomorphisms. *Int. J. Comput. Vis.* 2005;vol. 61(no. 2):139–139



Michael Miller

Large Deformation Diffeomorphic Metric Mapping (LDDMM)

大变形微分同胚度量映射 (LDDMM)

Large Deformation Diffeomorphic Metric Mapping is an image registration algorithm that minimises the following:

$$\mathcal{E} = \frac{1}{2} \int_{t=0}^1 \|L\mathbf{v}_t\|^2 dt + \frac{1}{2\sigma^2} \|f - \mu(\varphi_1^{-1})\|^2$$

$$\text{where } \varphi_0 = \text{Id}, \frac{d\varphi}{dt} = \mathbf{v}_t(\varphi_t)$$


算法的目标是找到一个速度场 $\mathbf{v}$ ，使得总能量 $\mathcal{E}$ 最小化。注：第一项保平滑，第二项保相似。

Differential Operator(微分算子): 指的是惩罚项里的 L ，用于保证平滑性

Large Deformations (大变形) : 通过积分微小的速度，处理非常大的、复杂的形变

Geodesic Distances(测地线距离): 找到的最优路径数学上被称为 “测地线”

Example



整个空间的扭曲是全局性的、平滑的、连续的。

Jacobian Matrix

- The Jacobian matrix of transformation (变换的雅可比矩阵) :

$$J(p) = \begin{bmatrix} \frac{\partial T_x(p)}{\partial x} & \frac{\partial T_y(p)}{\partial y} & \frac{\partial T_z(p)}{\partial z} \\ \frac{\partial T_y(p)}{\partial x} & \frac{\partial T_y(p)}{\partial y} & \frac{\partial T_y(p)}{\partial z} \\ \frac{\partial T_z(p)}{\partial x} & \frac{\partial T_z(p)}{\partial y} & \frac{\partial T_z(p)}{\partial z} \end{bmatrix}$$

- The determinant of this matrix measures how infinitesimal volumes change under the transformation and can be used to analyze the local behavior of the transformation.
- 该矩阵的行列式衡量了无穷小的体积在变换下是如何变化的，并可用于分析变换的局部行为。

$$J(p) = \det|J(p)| = \begin{cases} > 1 & \text{volume expansion (体积膨胀)} \\ = 1 & \text{no volume change (无体积变化)} \\ < 1 & \text{volume contraction (体积收缩)} \end{cases}$$

Summary

- Linear registration
 - Interpolation
 - Spatial transform
 - Similarity metric
 - Optimization
- Non-linear registration
 - Diffeomorphic transformation
 - Jacobian matrix
- Toolbox and pipeline